Definition av |

$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$

Bayes sats

$P(A \mid B) = P(B \mid A) \cdot P(A) \ / \ P(B)$

Alternativ form av Bayes sats:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B|A) \cdot P(A) + P(B|A^c) \cdot P(A^c)} \qquad \left(A^c = \bar{A}\right)$$

Lagen om total sannolikhet

$B_1, ..., B_5$ är en partitionering av S. Bayes sats ger då

$$P(B) = P(B|A) \cdot P(A) + P\left(B|\bar{A}\right) \cdot P\left(\bar{A}\right)$$

Räknelag

$P(\max(x_0, ..., x_n) \leq x) = P(x_1 \leq x, ..., x_n \leq x)$

Central Limit Theorem (CLIT / CLT / CGS)

Om x har fördelning med μ σ så är $\bar{x}$ normalfördelad med $\mu = \mu$, $\sigma = \frac{\sigma}{\sqrt{n}}$ n = storleken av stickprovet

Signifikansnivå vs konfidensnivå

Så, för ett test är konfidensnivån oddsen att alternativa hypotesen stämmer. konfidensnivå = 1 - signifikansnivå

Typ I fel = **signifikansnivå** = $\alpha =$
$\boldsymbol{P}(\text{Förkasta } H_0 \mid H_0 \text{ är sann})$

Typ 2 fel = $\boldsymbol{P}(\text{Acceptera } H_0 \mid H_0 \text{ är falsk})$

Styrka = **konfidensnivå** =
$\boldsymbol{P}(\text{Förkasta } H_0 \mid H_A \text{ är sann}) = 1 - \text{typ II fel}$

P-värdet för en observation Z_{obs} av Z är $P(Z > Z_{\text{obs}})$ är sannolikheten att nollhypotesen gäller. (säg inte det för statistiker kommer slå dig)

konfidens-interval

2-sidigt: $\bar{X} = \bar{x} \pm z_{\alpha \ / \ 2} * \text{STD}_{\text{ERR}}$ 1-sidigt: $\bar{X} = \bar{x} \pm z_{\alpha} * \text{STD}_{\text{ERR}}$ Där $\text{STD}_{\text{ERR}} = \frac{s}{\sqrt{n}}$

Regression

$SS_{\text{TOTAL}} = \sum_i (y_i - \bar{y})^2$

$SS_{\text{REG}} = \sum_i (\hat{y_i} - \bar{y})^2$

$SS_{\text{ERR}} = \sum_i (y_i - \hat{y})^2$

$R^2 = \frac{SS_{\text{REG}}}{SS_{\text{TOTAL}}}$

R^2 är andelen av den totala variationen förklarad av modellen.

$P(\max(x_0, ..., x_n) \leq x) = P(x_1 \leq x, ..., x_n \leq x)$

Väntevärde och varians

Definition

$\text{Var}[X] = \sum_x (x - \mu)^2 \cdot px(x) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

$\sigma = \text{Std}(x) = \sqrt{\text{Var}(X)}$

Stickprovsvarians

$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 = \frac{1}{n-1} \left(\sum_{i=1}^{n} x_i^2 - \frac{1}{n} \left(\sum_{i=1}^{n} x_i \right)^2 \right)$

Räknelagar

$\mathbb{E}[c] = c$ om c är en konstant

$\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$ med a,b,c konstanter

$\text{Var}[aX + b] = a^2 \ \text{Var}[X]$

$\text{Var}[aX + bY + c] = a^2 \ \text{Var}[X] + b^2 \ \text{Var}[Y] + 2ab \ \text{Cov}(X, Y)$ med a,b,c konstanter

$P(A|B) = \frac{P(A \cup B)}{P(B)}$

$\text{cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = \sum_i ((x_i - \bar{x})(y_i - \bar{y})) = E(XY) - E[X] * E[Y]$

Om X, Y Oberoende:

$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

$\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y]$

Chebyshevs olikhet

$\mathbb{P}(|X - \mu| > \varepsilon) \leq \left(\frac{\sigma}{\varepsilon}\right)^2$

Normalfördelning:

Hur summerar normalfördelning

$X \sim \text{norm}(\sigma = \sigma_x, \mu = \mu_x)$

$Y \sim \text{norm}(\sigma = \sigma_y, \mu = \mu_y)$

$X + Y \sim \text{norm}\left(\sigma = \sqrt{(\sigma_x)^2 + (\sigma_y)^2}, \mu = \mu_x + \mu_y\right)$

StandardError

När du summerar varianser och tar medelvärdet av dem $\text{STD}_{\text{ERR}} = \frac{s^2}{n}$

När du tar standardavvikelser på ett medelvärde $\text{STD}_{\text{ERR}} = \frac{s}{\sqrt{n}}$

Konvertera Gamma till Poisson

$$P(\text{Gamma}(\alpha, \lambda) > k) = P(\text{Poisson}(\lambda * k) < \alpha)$$

Där α är ett heltal. Fungerar lika för $<, >, \leq$ och $\geq$.

Central Limit Theorem (CLIT / CLT / CGS)

Om x har fördelning med μ σ så är $\bar{x}$ normalfördelad med $\mu = \mu$, $\sigma = \frac{\sigma}{\sqrt{n}}$.

n = storleken av stickprovet

Applikationer

Om n är stort gäller (notera "- 0.5"!):

$$P(\text{Binom}(n, p) \geq a) \approx$$
$$P(\text{Norm}(\mu = pq, \sigma = np(1-p)) \geq a - 0.5)$$

Skattning av parametrar

$\hat{\theta}$ är en väntevärdesriktig skattning av θ omm $\mathbb{E}\left[\hat{\theta}\right] = \theta$

$\hat{\theta}$ är en konsistent skattning av θ omm $\text{Var}\left[\hat{\theta}\right] \to 0$ då $n \to \infty$ där n är storleken på stickprovet

Hypotestest

Allmänt: H_0 vs H_A

1. Välj teststatistika, $T = T(X_1, ..., X_n)$.
2. Beräkna nollfördelningen för T, dvs samplingfördelningen för T om H_0 är sann.
3. Bestäm förkastningsregionen R i nollfördelningen så att $P(T \in R \mid H_0) = \alpha$).
4. Förkasta H_0 på signifikansnivån α om $T_{\text{obs}} \in R$, där T_{obs} är det

observerade värdet på T.

Z-test

Hypotestest för när X är normalfördelad. Normalisera först X till $Z = \frac{X - \mu_0}{\sigma}$ Jämför sedan Z med $z_{\alpha\ /\ 2}$ eller z_α. Använda $z_{\alpha\ /\ 2}$ för tvåsidigt test och z_α för ensidigt test. μ_0 är μ-värdet enligt noll-hypotesen H_0.

Z-test för $\bar{X}$

När vi gör test för ett medelvärde normaliserar vi istället genom $Z = \frac{\bar{X} - \mu_0}{s\ /\ \sqrt{n}}$

T-test

Samma som för Z-test men jämför med t-tabellen istället (t_α eller $t_{\alpha\ /\ 2}$). Frihetsgrader "df" i t-tabellen är oftast n - 1 men ibland n - 2 för att fucka med oss. För $\bar{X}$ är df $= n - 1$. För en linjär regressionsmodell är df = n - antal variabler i regressionsmodellen.

Signifikansnivå vs konfidensnivå

Så, för ett test är konfidensnivån oddsen att alternativa hypotesen stämmer. konfidensnivå = 1 - signifikansnivå

Typ I fel = **signifikansnivå** = $\alpha =$ $\boldsymbol{P}(\text{Förkasta } H_0 \mid H_0 \text{ är sann})$

Typ 2 fel = $\boldsymbol{P}(\text{Acceptera } H_0 \mid H_0 \text{ är falsk})$

Styrka = **konfidensnivå** = $\boldsymbol{P}(\text{Förkasta } H_0 \mid H_A \text{ är sann}) = 1 - \text{typ II fel}$

P-värdet för en observation Z_{obs} är $P(Z > Z_{\text{obs}})$

konfidens-interval

2-sidigt: $\bar{X} = \bar{x} \pm z_{\alpha\ /\ 2} * \text{STD}_{\text{ERR}}$

1-sidigt: $\bar{X} = \bar{x} \pm z_\alpha * \text{STD}_{\text{ERR}}$

Där $\text{STD}_{\text{ERR}} = \frac{s}{\sqrt{n}}$

Regression

$SS_{\text{TOTAL}} = \sum_i (y_i - \bar{y})^2$

$SS_{\text{REG}} = \sum_i (\hat{y_i} - \bar{y})^2$

$SS_{\text{ERR}} = \sum_i (y_i - \hat{y})^2$

$R^2 = \frac{SS_{\text{REG}}}{SS_{\text{TOTAL}}}$

R^2 är andelen av den totala variationen förklarad av modellen.

$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$

$S_{xy} = (n - 1)\ \text{cov}(x, y)$

$S_{xx} = (n - 1)\ \text{var}(x)$

lutningen b_1

$b_1 = \frac{s_{xy}}{s_{xx}} = \frac{\sum_i (x_i - \bar{x}) y_i}{s_{xx}}$

$\text{var}(b_1) = \frac{\sum_i (x_i - \bar{x}^2\ \text{var}(y_i))}{s_{xx}^2} = \frac{\sigma^2}{s_{xx}}$

konstanttermen b_0

$b_0 = \bar{y} - b_1 \bar{x}$

konfidensintervall och hypotestest för b_1

$b_1 \pm t_{\alpha\ /\ 2} \frac{s}{\sqrt{S_{xx}}}$

$t = \frac{b_1 - B}{s\ /\ \sqrt{S_{xx}}}$

konfidensintervall för medelvärdet av y vid en punkt x

om $y = b_0 + b_1 * x$ då är konfidensintervallet för Y

$$y \pm t_{\alpha\ /\ 2} \cdot s \cdot \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}}}$$

där t-fördelningen har n - 2 frihetsgrader, och $s^2 = \text{SS}_{\text{ERR}}\ /\ (n - 2)$ där $\text{SS}_{\text{ERR}} = \sum_i \left(y_{\text{obs,i}} - y_i\right)^2$ där $y_{\text{obs,i}}$ är det observerade värdet och y_i är värdet från den linjära regressionsmodellen.

konfidensintervallet för ett specifikt y vid en punkt x

Samma som ovan men

$$y \pm t_{\alpha\ /\ 2} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}}}$$

Bayesiansk estimator

$$\mathbb{E}(\theta \mid x) = \int \theta \pi(\theta \mid x) d\theta$$

Bayesiansk konfidensintervall (kredibilitetsintervall)

$P(\theta \in [a, b] \mid x) = \int_a^b \pi(\theta \mid x) d\theta = 0.95$. Dela sen upp i $P(\theta \leq a) = \int_{-\infty}^a \pi(\theta \mid x) d\theta = 0.025$ och $P(\theta \leq b) = \int_{-\infty}^b \pi(\theta \mid x) d\theta = 0.975$ och beräkna a samt b för hand eller med dator.

Bayesiansk hypotestestet

$H_0 : \theta \in \Theta_0$ vs $H_A : \theta \in \Theta_A$. Förkasta H_0 om $\pi(\Theta_0 \mid x) < \pi(\Theta_A \mid x)$